VYSOKÉ UČENÍ TECHNICKÉ V BRNĚ
FAKULTA INFORMAČNÍCH TECHNOLOGIÍ

Konvoluční neuronové sítě

Projekt: Generování řeči z textu – EmoTTSe

Jana Kováčiková (xkovac59)
Alexander Rastislav Okrucký (xokruc00)

10. mája 2026

Cieľ projektu

Cieľom projektu je návrh a implementácia modelu na generovanie reči z textu s dôrazom na emócie. Tieto modely sa často označujú ako Expressive text-to-speech (expresívna syntéza reči). Cieľom nie je vygenerovať čo najviac vierohodnú reč, ale vytvorenie nástroja, na prerozprávanie krátkeho textu s dôrazom na jednu vybranú emóciu.

Vstupom je krátky text v angličtine, ktorý má model prerozprávať s dôrazom na zvolenú emóciu.

Existujúce riešenia

Ako dve komerčné riešenia, ktoré nás oslovili sú TTS od ElevenLabs[1] a Inworld[2]. Obe spoločnosti ponúkajú svoje systémy iba formou uzavrených API služieb a nie sú open source. Tieto riešenia podporujú rôzne emócie, možnosť vlastných hlasov, kontrolu rýchlosti reči a stabilitu generovaného výstupu. Stabilita ovplyvňuje to, ako dobre bude systém generovať reč, vzhľadom k zadanému textu. Nízka stabilita dovoľuje do systému vnášať nekonzistencie a generovať neštandardné zvuky. Samozrejme náš projekt sa týmto riešeniam ani z ďaleka nepribližuje.

Dátové sady

Aby sme zabezpečili čo najlepšiu kvalitu trénovacích dát a vedeli ich validovať, bolo potrebné spojiť niekoľko datasetov do jedného. Pri výbere dát sme sa zamerali na datasety s emóciami, ktoré sú kompatibilné s nami zvoleným klasifikátorom. Po vyhodnotení baseline riešenia, sa časť dát ukázala ako nevhodná a pre finálny model sme upravili dátovú sadu.

Baseline dátová sada

Z nasledujúcich dátových sád, sme vytvorili jednu spoločnú pre trénovanie a vyhodnotenie baseline riešenia:

- Open Speech and Language Resources – EmoV_DB[3] $\sim$ 12 hodín audio nahrávok
- Open Speech and Language Resources – EMNS[4] $\sim$ 2 hodiny audio nahrávok
- Toronto emotional speech set (TESS)[5] $\sim$ 2 hodiny audio nahrávok

Emócie, ktoré používame spolu s počtom nahrávok, ktoré máme k dispozícii v datasete:

- Happy – 400 nahrávok ($\sim$ 13 minút)
- Amused – 1317 nahrávok ($\sim$ 1 hodina 53 minút)
- Angry – 1669 nahrávok ($\sim$ 1 hodina 45 minút)

[1] https://elevenlabs.io/
[2] https://inworld.ai/tts
[3] https://www.openslr.org/115/
[4] https://www.openslr.org/136/
[5] https://utoronto.scholaris.ca/collections/036db644-9790-4ed0-90cc-be1dfb8a4b66/search

- Neutral – 1669 nahrávok ($\sim$ 1 hodina 54 minút)
- Sad – 400 nahrávok ($\sim$ 16 minút)
- Surprised – 400 nahrávok ($\sim$ 13 minút)

Dataset Toronto emotional speech set má na začiatku audio nahrávok slovné spojenie „Say the word...", čo negatívne ovplyvnilo trénovanie. Síce sú emócie pomerne dobre klasifikovateľné (viď časť Vyhodnotenie), vo vygenerovaných nahrávkach sa na začiatku objavuje stopa pripomínajúca slovo „say th...". Okrem toho nebola výsledná kvalita dostačujúca, čo ukazujú aj metriky WER a CER. Vo finálnom riešení sme tieto nahrávky nahradili nahrávkami z iného datasetu.

Dátová sada pre finálne riešenie

Oproti baseline riešeniu sme nahradili dáta pre emócie happy, sad a surprised a rozhodli sme sa vynechať emóciu amused (viď časť Vyhodnotenie). Z nasledujúcich dátových sád, sme vytvorili jednu spoločnú pre trénovanie a vyhodnotenie finálneho riešenia:

- Open Speech and Language Resources – EmoV_DB[6] $\sim$ 12 hodín audio nahrávok
- Open Speech and Language Resources – EMNS[7] $\sim$ 2 hodiny audio nahrávok
- Publicly Available Emotional Speech Dataset (ESD) for Speech Synthesis and Voice Conversion[8]

Emócie, ktoré používame spolu s počtom nahrávok, ktoré máme k dispozícii v datasete:

- Happy – 350 nahrávok ($\sim$ 15 minút)
- Angry – 1669 nahrávok ($\sim$ 1 hodina 45 minút)
- Neutral – 1669 nahrávok ($\sim$ 1 hodina 54 minút)
- Sad – 350 nahrávok ($\sim$ 19 minút)
- Surprised – 350 nahrávok ($\sim$ 15 minút)

Baseline riešenie

Ako baseline sme zvoli riešenie – generovanie podľa emočných nahrávok existujúcim systémom FastPitch[9]. Dotrénovali sme 6 rôznych modelov s pôvodnou architektúrou zvoleného modelu a ku každému modelu aj príslušný neurálny vokodér HiFi-GAN[10].

Finálne riešenia

Ako referenčný model používame v oboch riešeniach model FastPitch. Jedná sa o neautoregresívny feed-forward model založený na architektúre FastSpeech, ktorý Nvidia vylepšia.

[6] https://www.openslr.org/115/
[7] https://www.openslr.org/136/
[8] https://github.com/HLTSingapore/Emotional-Speech-Data
[9] https://pytorch.org/hub/nvidia_deeplearningexamples_fastpitch/
[10] https://catalog.ngc.nvidia.com/orgs/nvidia/teams/tao/models/speechsynthesis_hifigan?version=deployable_v1.0

Model so zmenou architektúry

Existujúci model FastPitch sme doplnili o nami naprogramované časti zamerané na emócie (viď obrázok 1). Pred existujúce prediktory: pitch predictor, duration predictor a energy predictor, sme doprogramovali emotion predictor, ktorý generuje emócie na základe emotion embeddings. Emotion embeddings budú extrahované a následne upravené zo vstupného textu.

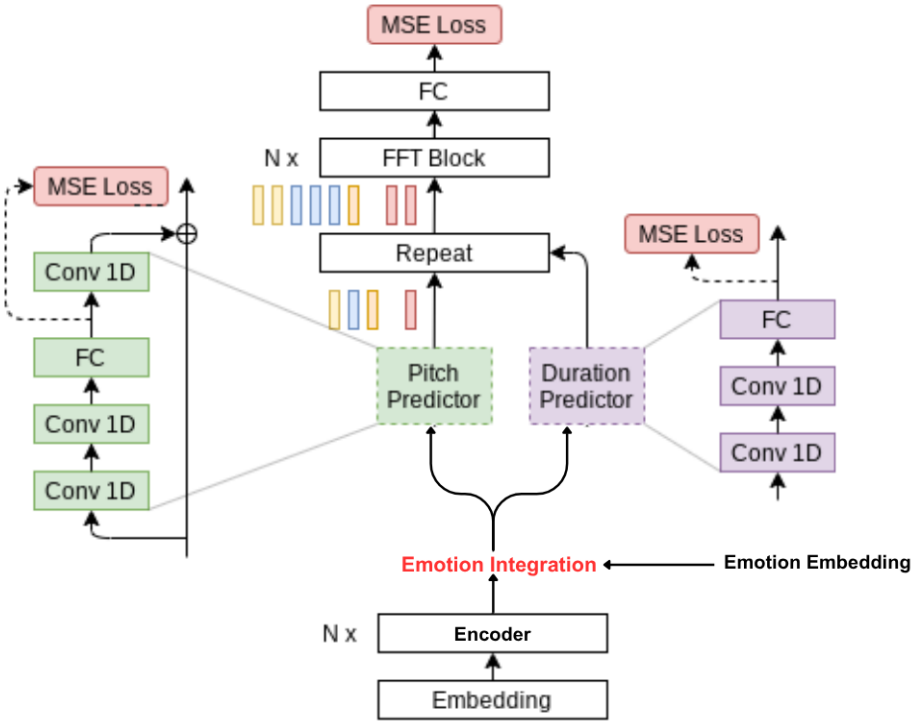

Obr. 1: Schéma modelu FastPitch s integráciou emócií (pôvodná schéma s doplnením našej časti). Prevzaté z [1], upravené.

Napriek úpravám architektúry na potrebných miestach a dodatočnému dotrénovávaniu modelu FastPitch a príslušného neurálneho vokodéru HiFi-GAN[11], sa nám týmto spôsobom nepodarilo úspešne dotrénovať model. Domnievame sa, že zásah do architektúry bol príliš rozsiahly a pri finetuningu sme model odnaučili rozprávať. Spektrogramy vygenerovaných nahrávok síce vykazujú znaky reči, no slová vo vygenerovanej nahrávke sú ťažko rozpoznateľné a znejú plechovo/roboticky.

[11] `https://huggingface.co/nvidia/tts_hifigan`

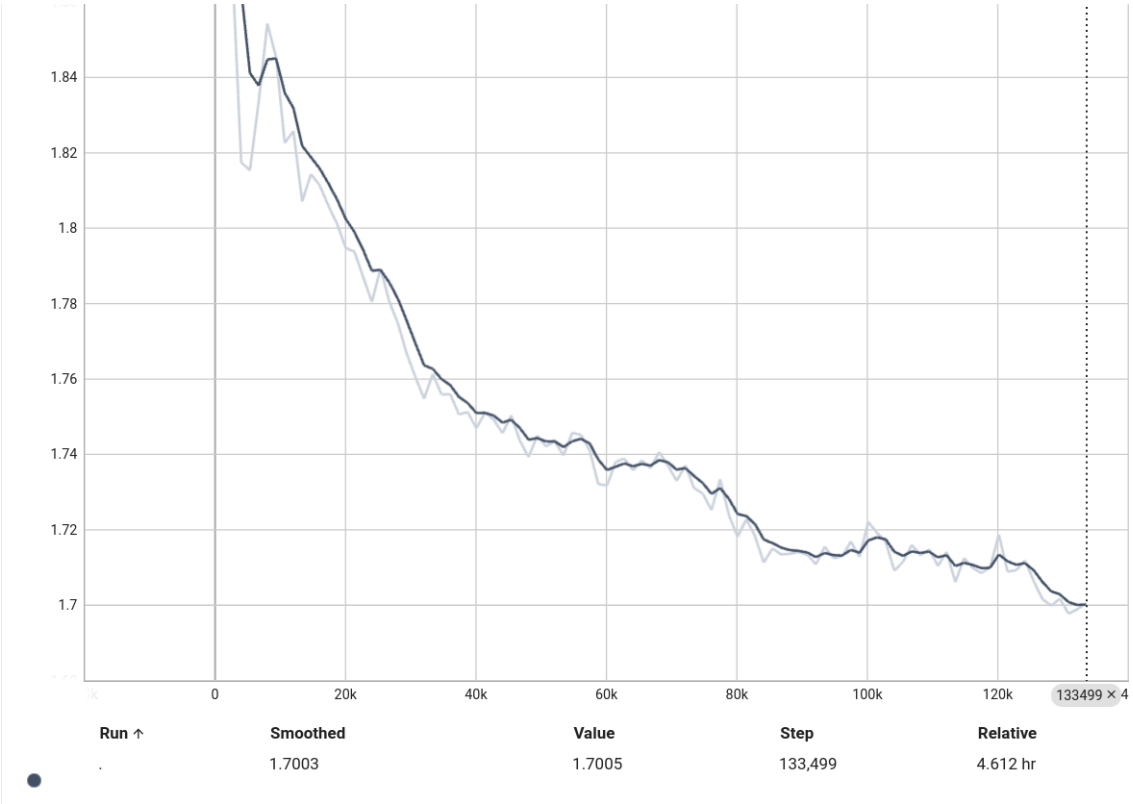

Obr. 2: Vývoj loss funkcie v priebehu trénovania.

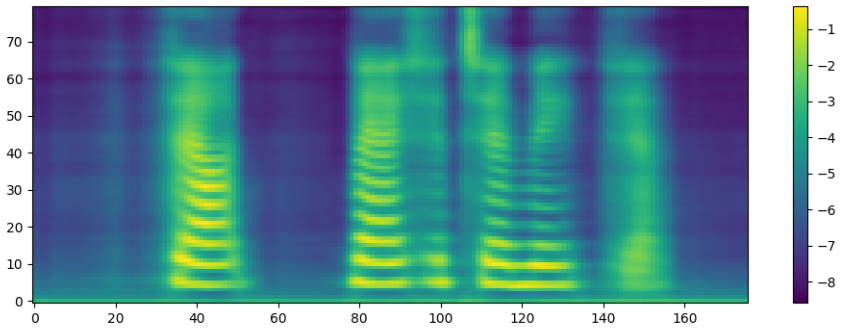

Obr. 3: Ukážka mel spektrogramu vygenerovanej nahrávky. Veta: Hello, nice to meet you.

Vo vygenerovaných wav súboroch sú viditeľné mierne rozdiely (napríklad, ak si nahrávku otvoríte v programe Audacity), pri zmene zvolenej emócie, no nie sú počuteľné. Aj napriek dobre vyzerajúcej loss funkcii, by úspešné dokončenie tohto prístupu vyžadovalo významne väčšie množstvo kvalitných trénovacích dát.

End-to-end riešenie – generovanie podľa emočných nahrávok existujúcim systémom

Existujúci model FastPitch sme dotrénovali zvlášť pre každú emóciu na základe existujúcich emočných nahrávok bez zmeny architektúry modelu. Rozhodli sme sa pre integráciu modelov natrénovaných rovnako ako v baseline riešení a integrovali sme ich do jedného end-to-end systému, ktorý zavolá príslušný model na základe požadovanej emócie na vstupe. Z dôvodu nízkeho rozpoznania v baseline riešení sme z tohoto systému vynechali emóciu Amused. S baseline riešenia sme použili natrénované modely pre emócie neutral a angry. Dodatočne sme dotrénovali modely pre emócie happy, sad a surprised, ktoré mali v baseline riešení málo kvalitných trénovacích dát a zároveň mali najslabšiu kvalitu, ktorú sme posúdili podľa vypočutia vzorových nahrávok. Finálne riešenie teda pozostáva z piatich modelov a vokodérov integrovaných do jedného systému, ktorý vyberie model na generovanie reči na základe zvolenej emócie.

Systém môžete nájsť na Scratchi: `/mnt/scratch/tmp/xokruc00/knn`

Ukážka vstupu: `python end_to_end_system.py -s "Hello world." -e angry -o angry.wav`

Vyhodnotenie

Pre vyhodnotenie baseline riešenia, ako aj finálneho systému sme použili 3 vyhodnocovacie stratégie: klasifikácia emócií, Word Error Rate (WER) a Character Error Rate (CER). Pre klasifikáciu emócií sme zvolili model Speech Emotion Recognition with Whisper[12]. Pri verifikovaní prepisu reči s použitím modelu Parakeet sme zvolili metriky WER a CER, ktoré sa často používajú v rámci automatického rozpoznávania reči.

Baseline riešenie

Pre každú emóciu sme vygenerovali 200 rovnakých viet a nahrávky sme následne dali klasifikovať. Počet správne klasifikovaných nahrávok:

- Happy – 178 nahrávok $\sim 89\%$
- Amused – 0 nahrávok $\sim 0\%$
- Angry – 146 nahrávok $\sim 73\%$
- Neutral – 156 nahrávok $\sim 78\%$
- Sad – 134 nahrávok $\sim 67\%$
- Surprised – 42 nahrávok $\sim 21,5\%$

Ak by sme v prípade vyhodnotenia emócie amused brali do úvahy aj emóciu happy, ktorá sa mierne podobá, bolo by správne vyhodnotených 6 nahrávok z 200 $\sim 3\%$, čo je stále veľmi málo.

[12] `https://huggingface.co/firdhokk/speech-emotion-recognition-with-openai-whisper-large-v3`

Vygenerované nahrávky s pridanou emóciou sme dali prepísať a porovnali ich s vetami, podľa ktorých boli vygenerované:

Emócia	**WER** [%]	**CER** [%]
Happy	70	42
Amused	48	27
Angry	14	5
Neutral	7	2
Sad	27	11
Surprised	58	25

Tabuľka 1: Vyhodnotenie baseline riešenia podľa metrík WER a CER. Nižšia hodnota je lepšia.

Finálne end-to-end riešenie

Vo finálnom riešení sme ponechali 2 natrénované modely z baseline riešenia pre emócie angry a neutral (tie sme taktiež nanovo vyhodnotili) a vynechali sme emóciu amused. Pre každú emóciu sme vygenerovali 200 viet (rovnakých ako pri baseline riešení) a nahrávky sme dali klasifikovať. Počet správne klasifikovaných nahrávok:

- Happy – 146 nahrávok $\sim 73\%$
- Angry – 146 nahrávok $\sim 73\%$
- Neutral – 156 nahrávok $\sim 78\%$
- Sad – 2 nahrávky $\sim 1\%$
- Surprised – 187 nahrávok $\sim 94\%$

Najmenší počet správne rozpoznaných nahrávok dosahuje emócia sad. Pri počúvaní vygenerovaných nahrávok je emóciu počuť, no to je subjektívne a klasifikátor ju vo väčšine prípadov detekuje ako emóciu neutral. Ako môžete vidieť, celkovo klesol počet správne rozpoznaných nahrávok, no nahrávky sú oveľa zrozumitelnejšie. Výsledná kvalita dát výrazne stúpla, čo môžete vidieť na metrikách WER a CER.

Vygenerované nahrávky s pridanou emóciou sme dali prepísať a porovnali ich s vetami, podľa ktorých boli vygenerované:

Emócia	**WER** [%]	**CER** [%]
Happy	8	2
Amused	48	27
Angry	14	5
Neutral	7	2
Sad	6	2
Surprised	12	3

Tabuľka 2: Vyhodnotenie finálneho riešenia podľa metrík WER a CER. Nižšia hodnota je lepšia.

Github repozitár

https://github.com/dzejnwashere/KNN_Project_TTS

Natrénované modely a vokodéry

Baseline aj finálne natrénované modely a vokodéry: https://drive.google.com/drive/folders/1OwO7topPZT9lotsyYq3CYtdqgYQTf9-z?usp=sharing. V zložke sa nachádzajú aj ukážky vygenerovaných nahrávok.

Prehlásenie

Pre účely konzultovania a riešenia niektorých errorov sme použili jazykový model Claude.

Literatúra

[1] LAŃCUCKI, A. *FastPitch: Parallel Text-to-speech with Pitch Prediction*. 2021. Dostupné z: https://arxiv.org/abs/2006.06873.